



第7章 估计(Estimation)

- 1. 统计性估计
- 2. 关于总体均值的估计
- 3. 关于总体比例的估计
- 4. 关于总体方差的估计
- 5. 置信区间的理解

2/22



1. 统计性估计



[定义 10-1] 点估计(point estimation)

: 通过估计量的观测值来估计参数的真值的过程

- 无偏性(unbiasedness) $E(\hat{\theta}) = \theta$ $E(\bar{X}) = \mu, E(S^2) = \sigma^2$
- [例 10-1] 从均值为µ的总体中抽取样本,求样本均值时,可知样本均值是关于µ的无偏估计量。

$$E(\overline{X}) = \frac{1}{n}E(X_1 + X_2 + \dots + X_n) = \frac{1}{n}n\mu = \mu$$

[例 10-2] 从总体方差为 σ^2 的总体中抽取n个样本,求证样本方差 S^2 是总体方差 σ^2 的无偏估计量。

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1) \implies E\left[\frac{(n-1)S^2}{\sigma^2}\right] = n-1 \implies E(S^2) = \sigma^2$$

3/22

3

1.1 点估计



[例 10-3] 从均值为 μ , 方差为 σ^2 的总体中抽取n个样本,在求样本均值X-bar和其他估计量 $Y=(X_1+X_2)/2$ 时,探讨两估计量的无偏性,并对其方差进行比较。

$$E(\overline{X}) = \mu, \ Var(\overline{X}) = \sigma^2 / n$$

$$E(\overline{X}) = E\left(\frac{1}{n}\sum_{i=1}^n X_i\right) = \frac{1}{n}\sum_{i=1}^n E(X_i) = \frac{1}{n}\sum_{i=1}^n \mu = \mu$$

$$Var(\overline{X}) = Var\left(\frac{1}{n}\sum_{i=1}^n X_i\right) = \frac{1}{n^2}\sum_{i=1}^n Var(X_i) = \frac{1}{n^2}\sum_{i=1}^n \sigma^2 = \frac{\sigma^2}{n}$$

$$E(Y) = E\left(\frac{X_1 + X_2}{2}\right) = \frac{2\mu}{2} = \mu$$

$$Var(Y) = Var\left(\frac{X_1 + X_2}{2}\right) = \frac{2\sigma^2}{4} = \frac{\sigma^2}{2} > \frac{\sigma^2}{n} \quad (n \ge 3)$$

4/22



1.2 区间估计



[定义 10-2] 区间估计(interval estimation)

:含参数真值的概率决定置信水平为1-农的置信区间的过程

- 置信区间(confidence interval) $\left[\hat{\boldsymbol{\theta}}_{\!\scriptscriptstyle L},\hat{\boldsymbol{\theta}}_{\!\scriptscriptstyle U}\right]$ 含参数真值的概率成为置信水平为1- α 的区间
- 置信水平(confidence level) 置信区间包含参数真值的概率(1- α) $P(\hat{\theta}_L < \theta < \hat{\theta}_U) = 1 - \alpha$
- 显著性水平(significance level) 置信区间不包含参数真值的概率(α) $1-P(\hat{\theta}_L < \theta < \hat{\theta}_U) = \alpha$

5/2

5

2. 关于总体均值的估计



[定理 10-1] 总体均值的置信区间(已知总体方差的情况)

: 关于正态总体的总体均值 μ 的置信水平(1- α)置信区间(confidence interval), 100(1- α)% 置信区间

$$\left[\overline{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \, \overline{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right] = \left[\overline{X} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

[证明]

$$1 - \alpha = P\left(-z_{1-\alpha/2} < Z < z_{1-\alpha/2}\right) = P\left(-z_{1-\alpha/2} < \frac{\overline{X} - \mu}{\sigma / \sqrt{n}} < z_{1-\alpha/2}\right)$$
$$= P\left(\overline{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \overline{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right)$$

6/22



2.1 总体方差已知情况下的估计



[例 10-4] 一个巧克力的重量符合总体标准差为5(g)的正态分布,随机抽取50个巧克力,重量的样本均值为199.5(q)时,求95%置信区间。

$$\overline{X} = 199.5, \quad z_{0.975} \doteq 1.96$$

$$\left[199.5 \pm 1.96 \times \frac{5}{\sqrt{50}}\right] \doteq \left[199.5 \pm 1.386\right] = \left[198.114, 200.886\right]$$

- 置信区间的误差(error) $z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$
- 保持误差在一定水平以下所需样本个数

$$z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \delta \implies n \geq \left(z_{1-\alpha/2} \frac{\sigma}{\delta}\right)^2$$

[例 10-5] 在上述[例 10-4]的95%置信水平中,若要保持置信区间的误差小于等于 1.2, 求所需的样本大小。

$$n \ge \left(1.96 \times \frac{5}{1.2}\right)^2 \doteq 66.7 \implies n \ge 67$$

7/22

7

2.3 总体方差未知情况下的估计



[定理 10-3] 关于总体均值的置信区间(总体方差未知的情况) : 在不知总体方差的情况下,关于正态总体均值的100(1-α)% 置信区间 (confidence interval)

$$\left[\overline{X} - t_{1-\alpha/2;(n-1)} \frac{S}{\sqrt{n}}, \, \overline{X} + t_{1-\alpha/2;(n-1)} \frac{S}{\sqrt{n}}\right] = \left[\overline{X} \pm t_{1-\alpha/2;(n-1)} \frac{S}{\sqrt{n}}\right]$$

[证明]

$$\frac{\overline{X} - \mu}{S / \sqrt{n}} \sim t(n-1) \implies P\left(-t_{1-\alpha/2:(n-1)} < \frac{\overline{X} - \mu}{S / \sqrt{n}} < t_{1-\alpha/2:(n-1)}\right) = 1 - \alpha$$

$$P\left(\overline{X} - t_{1-\alpha/2:(n-1)} \frac{S}{\sqrt{n}} < \mu < \overline{X} + t_{1-\alpha/2:(n-1)} \frac{S}{\sqrt{n}}\right) = 1 - \alpha$$

$$\left[\overline{X} - t_{1-\alpha/2:(n-1)} \frac{S}{\sqrt{n}}, \overline{X} + t_{1-\alpha/2:(n-1)} \frac{S}{\sqrt{n}}\right] = \left[\overline{X} \pm t_{1-\alpha/2:(n-1)} \frac{S}{\sqrt{n}}\right]$$

8/22



2.3 总体方差未知情况下的估计



[例 10-8] 一个巧克力的重量符合正态分布,从中随机抽取16个巧克力,其重量的样本均值为199.5(g),样本方差为25.0时,求关于总体均值的95%置信区间。

$$\overline{X} = 199.5, \ S = 5.0, \ t_{0.975:15} \doteq 2.131$$

$$\left[199.5 \pm 2.131 \frac{5}{\sqrt{16}}\right] \doteq \left[199.5 \pm 2.664\right] = \left[196.836, 202.164\right]$$

```
# 定义函数(样本个数、样本均值、样本标准差、显著性水平)
tci1 <- function(n, xb, s, alp) {
        err <- qt(1-alp/2, n-1)*s/sqrt(n)
        cat("[", xb-err, ",", xb+err,"]\n")}
# 运行函数
tci1(16, 199.5, 5, 0.05)
[ 196.8357 , 202.1643 ]
```

9/22

9

2.3 总体方差未知情况下的估计



[例 10-9] 一个巧克力的重量符合正态分布,从中随机抽取50个巧克力, 对其重量测量的结果如下所示,求关于总体均值的95%置信区间。

$$\sum_{i=1}^{50} x_i = 9,973 \qquad \sum_{i=1}^{50} x_i^2 = 1,990,407$$

$$\bar{X} = \frac{9,973}{50} = 199.46 \qquad S = \sqrt{\frac{1,990,407 - 9,973^2 / 50}{50 - 1}} \doteq 4.993$$

$$t_{0.975;49} \doteq 2.010$$

$$\left[199.46 \pm 2.010 \times \frac{4.993}{\sqrt{50}} \right] \doteq \left[199.46 \pm 1.402 \right] = \left[198.058,200.862 \right]$$

10/22



3. 关于总体比例的估计



[定理 10-5] 总体比例的近似置信区间

: 当样本大小n取值较大时,关于总体比例p的100(1-α)%近似置信区间

$$\hat{p} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

$$\hat{p} = \frac{X}{n}$$

$$\begin{split} \frac{X - np}{\sqrt{np(1 - p)}} &= \frac{\hat{p} - p}{\sqrt{p(1 - p)/n}} \stackrel{a}{\sim} N(0, 1) \\ 1 - \alpha &= P(-z_{1 - \alpha/2} < Z < z_{1 - \alpha/2}) \quad \simeq P\left(-z_{1 - \alpha/2} < \frac{\hat{p} - p}{\sqrt{p(1 - p)/n}} < z_{1 - \alpha/2}\right) \\ &\simeq P\left(-z_{1 - \alpha/2} < \frac{\hat{p} - p}{\sqrt{\hat{p}(1 - \hat{p})/n}} < z_{1 - \alpha/2}\right) \\ \Rightarrow P\left(\hat{p} - z_{1 - \alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} < p < \hat{p} + z_{1 - \alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}\right) \simeq 1 - \alpha \end{split}$$

11

3.1 总体比例的估计



[例 10-13] 在某一工艺流程中随机抽取200个产品进行检查,发现了15个 不良品, 求该关于该工艺流程不良率的95%置信区间。

$$\hat{p} = \frac{X}{n} = \frac{15}{200} = 0.075 \qquad z_{0.975} = 1.96$$

$$\left[0.075 \pm 1.96 \times \sqrt{\frac{0.075(1 - 0.075)}{200}} \right] = \left[0.075 \pm 0.037 \right] = \left[0.038, 0.112 \right]$$

定义正态近似置信区间函数(样本个数、成功次数、显著性水平) pci1 <- function(n, x, alp) {</pre>

p <- x/n

err \leftarrow qnorm(1-alp/2)*sqrt(p*(1-p)/n)

 $cat("[", p, "±", err, "] = [", p-err, ",", p+err,"]\footnote{\pi}n")}$

运行函数

pci1(200, 15, 0.05)

 $[0.075 \pm 0.03650351] = [0.03849649, 0.1115035]$

利用二项分布估计正确的置信区间(多少会出现差异)

binom.test(15,200)\$conf

[1] 0.0425828 0.1206842

attr(,"conf.level")

[1] 0.95



3.1 总体比例的估计



• 为使置信区间误差保持在一定水平一下,所需的样本个数

$$z_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \le \delta \implies n \ge \hat{p}(1-\hat{p})\left(\frac{z_{1-\alpha/2}}{\delta}\right)^{2}$$

$$p(1-p) = -(p-0.5)^{2} + 0.25 \implies p^{*} = 0.5 \implies n \ge 0.5^{2} \times \left(\frac{z_{1-\alpha/2}}{\delta}\right)^{2}$$

[例 10-14] 根据过去的经验,某一工艺流程的不良率为7.5% 95%置信区间,若要使关于总体比例的置信区间的误差达到0.02一下,则所需的样本大小是多少。

$$p = 0.075 \implies n \ge 0.075 \times (1 - 0.075) \left(\frac{1.96}{0.02}\right)^2 \doteq 666.3 \implies n \ge 667$$

■ 在完全不知总体比例p的情况下

$$\Rightarrow n \ge 0.5^2 \times \left(\frac{1.96}{0.02}\right)^2 \doteq 2400.9 \Rightarrow n \ge 2401$$

13/22

13

3.1 总体比例的估计




[例 10-14] (承上)

 $n \ge 666.253 \Rightarrow n \ge 667$ nsample(0.02)

 $n \ge 2400.912 \Rightarrow n \ge 2401$

14/22





15

4. 关于总体方差的估计



[定理 10-8] 关于总体方差的置信区间 :关于正态总体方差σ²的100(1-α)%置信区间

$$\left[\frac{(n-1)S^2}{\chi^2_{1-\alpha/2;n-1}}, \frac{(n-1)S^2}{\chi^2_{\alpha/2;n-1}}\right]$$

■ 卡方分布的分位数


$$P(\chi_{v}^{2} \leq \chi_{p;v}^{2}) \equiv p \implies P(\chi_{\alpha/2;v}^{2} \leq \chi_{v}^{2} \leq \chi_{1-\alpha/2;v}^{2}) = 1 - \alpha$$

$$\Rightarrow P(\chi_{\alpha/2;n-1}^{2} \leq \frac{(n-1)S^{2}}{\sigma^{2}} \leq \chi_{1-\alpha/2;n-1}^{2}) = 1 - \alpha$$

$$= P(\frac{(n-1)S^{2}}{\chi_{1-\alpha/2;n-1}^{2}} \leq \sigma^{2} \leq \frac{(n-1)S^{2}}{\chi_{\alpha/2;n-1}^{2}})$$

16/22





Τ,

4.1 总体方差的估计



[例 10-19] 某一生产工艺的品质特征值符合正态分布,为估计关于品质特征的方差,随机抽取了10个产品进行检查,所得结果如下所示。 求总体方差的95%置信区间。

20.0 21.5 20.9 19.8 22.5 20.3 23.6 18.0 23.3 17.8

$$S^{2} = \frac{4350.13 - 207.7^{2} / 10}{9} = \frac{36.201}{9} \doteq 4.022$$

$$\chi^{2}_{0.025,9} \doteq 2.700 \qquad \chi^{2}_{0.975,9} \doteq 19.023$$

$$\Rightarrow \left[\frac{36.201}{19.023}, \frac{36.201}{2.700} \right] \doteq \left[1.903, 13.408 \right]$$

18/22



5. 置信区间的理解



■ 对置信区间的误解


在置信区间[a, b],包含参数θ的概率为100(1-α)%。

■ 对置信区间的正确解析


任意置信区间[L, U],包含参数 θ 的真值的概率为 $100(1-\alpha)$ %,其置信区间中区间[a, b]为观测值。

19/22

19







21

